

Mon Projet Data Science

E-Commerce Sales Analysis & Prediction

Guide complet pour comprendre chaque ligne de code

par Khadija Sayoukh

1. C'est quoi ce projet en simple ?

Imagine que tu as un magasin en ligne. Tu as des milliers de transactions — des clients qui achètent des produits. Tu veux répondre à ces questions :

- Combien d'argent j'ai gagné ce mois-ci ?
- Quels sont mes meilleurs clients ?
- Si je vends un produit à 1000 euros, combien je vais gagner ?
- Comment je peux montrer tout ça à quelqu'un via internet ?

Ton projet répond à TOUTES ces questions. Il est divisé en 5 fichiers Python qui travaillent ensemble, plus un notebook pour voir les graphiques.

2. Les fichiers du projet - à quoi sert chacun ?

dataset_real.csv	Les vraies données. 6978 transactions réelles d'une boutique de vêtements internationale (2021-2022). C'est la matière première de tout le projet.
preprocessing.py	Le fichier qui nettoie et prépare les données. Comme laver des légumes avant de cuisiner.
model.py	Le cerveau du projet. Contient le modèle de Machine Learning qui apprend à faire des prédictions.
utils.py	Les graphiques. Contient les fonctions pour dessiner les courbes et les barres.
main.py	L'API. Permet à n'importe qui d'utiliser le projet via internet sans avoir Python.
analysis.ipynb	Le notebook Jupyter. Un document interactif où tu peux voir les graphiques et les résultats.
requirements.txt	La liste de courses. Dit à Python quelles bibliothèques installer.
README.md	La carte de visite sur GitHub. La première chose que les recruteurs voient.

3. dataset_real.csv - Les vraies donnees

Ce fichier contient 6978 lignes. Chaque ligne = une transaction réelle d'une boutique de vêtements qui vend à l'international.

Les colonnes du dataset

Transaction_ID	Le numero unique de chaque vente. Ex: TXN_000001
Date	La date de la vente. Ex: 2021-06-05
Customer_ID	Le nom du client. Ex: MULBERRIES BOUTIQUE
Produit	Le code du produit vendu. Ex: J0236
SKU	Le code exact avec la taille. Ex: J0236-SKD-M
Taille	La taille commandee. Ex: S, M, L, XL
Categorie	Le type de produit. Ex: Robe/Jupe, Ensemble, Homme
Quantite	Combien d'unites ont ete commande
Prix_Unitaire	Le prix d'un seul article en roupies indiennes
Prix_Final	Le prix total de la commande (Prix x Quantite)
Cout_Total	Ce que ca a coute de produire (55% du prix)
Profit	Ce qui reste apres avoir enleve le cout
Marge_%	Le pourcentage de profit. Environ 45% dans ce dataset

4. preprocessing.py - Nettoyer et preparer les donnees

Ce fichier contient 6 fonctions. Chaque fonction fait une chose précise sur les données.

Fonction 1 : load_data()

```
data = pd.read_csv(filepath)
```

Cette ligne lit le fichier CSV et le transforme en tableau Python. `pd.read_csv` c'est comme ouvrir un fichier Excel en code. Le résultat s'appelle un DataFrame - c'est un tableau avec des lignes et des colonnes.

Fonction 2 : clean_data()

```
cleaned = cleaned.dropna().drop_duplicates()
```

dropna() enleve les lignes ou il manque des informations. drop_duplicates() enleve les lignes qui sont identiques. Sans ce nettoyage, le modele ML apprendrait sur des donnees fausses et ferait de mauvaises predictions.

Fonction 3 : create_time_features()

```
data['Mois_Num'] = data['Date'].dt.month  
data['Jour_Semaine'] = data['Date'].dt.dayofweek
```

On extrait le mois et le jour de la semaine depuis la date. Pourquoi ? Parce que le modele ML ne comprend pas '2021-06-05' directement - il a besoin de chiffres. Donc on transforme la date en chiffres utiles.

Fonction 4 : calculate_metrics()

```
data['CA'] = data['Prix_Final']  
data['Revenu_Par_Unite'] = data['Prix_Final'] / data['Quantite']
```

On cree de nouvelles colonnes calculees. CA = Chiffre d'Affaires, c'est le revenu total. Revenu_Par_Unite c'est combien chaque article rapporte en moyenne.

Fonction 5 : segment_customers()

Cette fonction classe chaque client dans une des 3 categories :

VIP	Frequence >= 10 commandes ET montant total >= 50 000. Ce sont les meilleurs clients.
Regulier	Frequence >= 5 commandes. Clients qui reviennent souvent.
Occasionnel	Tous les autres. Acheteurs ponctuels.

Fonction 6 : prepare_ml_data()

```
features = ['Prix_Unitaire', 'Quantite', 'Mois_Num', 'Jour_Semaine']  
X = data[features].values  
y = data['CA'].values
```

On prepare les donnees pour le Machine Learning. X c'est ce qu'on donne au modele (les entrees). y c'est ce qu'on veut predire (la sortie). C'est comme un exercice de maths : X est la question, y est la reponse.

5. model.py - Le Machine Learning

C'est le fichier le plus important techniquement. Il contient une classe SalesPredictor qui encapsule le modele ML.

C'est quoi le Machine Learning ?

Le Machine Learning c'est apprendre a une machine a faire des predictions en lui montrant des exemples. Dans notre cas :

- On lui montre 5 582 transactions (80% du dataset)
- Pour chaque transaction, on lui dit : voici le prix, la quantite, le mois, le jour - et voici le CA que ca a genere
- Le modele trouve les patterns et apprend les regles
- Ensuite il peut predire le CA pour de nouvelles transactions qu'il n'a jamais vues

Les 3 algorithmes disponibles

Linear Regression	Le plus simple. Trace une ligne droite entre les donnees. Rapide mais pas tres precis.
Random Forest	Cree des centaines d'arbres de decision et fait la moyenne. Plus precis.
Gradient Boosting	Notre choix. Cree les arbres un par un, chacun corrigeant les erreurs du precedent. Le plus precis des trois.

La methode train()

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
```

On coupe les donnees en deux : 80% pour apprendre (train) et 20% pour tester (test). C'est comme apprendre avec un livre de cours et passer l'examen sur des questions que tu n'as jamais vues.

```
self.model.fit(X_train, y_train)
```

fit() c'est la ligne qui entraine vraiment le modele. C'est ici que la machine apprend.

Comment mesurer si le modele est bon ?

R2 Score	Mesure entre 0 et 1. Un R2 de 0.85 veut dire que le modele explique 85% de la variation du CA. Plus c'est proche de 1, mieux c'est.
RMSE	L'erreur moyenne des predictions. Si RMSE = 200, ca veut dire que en moyenne le modele se trompe de 200 roupies.

La methode predict()

```
X_input = np.array([[prix, quantite, mois, jour]])  
resultat = self.model.predict(X_input)[0]
```

On donne des nouvelles valeurs au modele et il predit le CA. C'est comme demander a quelqu'un qui a appris les maths de calculer une nouvelle somme.

6. utils.py - Les graphiques

Ce fichier contient les fonctions pour creer des graphiques avec matplotlib. Un graphique vaut mieux que 1000 chiffres.

plot_sales_evolution()

```
daily = data.groupby('Date')['Quantite'].sum()
ax.plot(daily['Date'], daily['Quantite'])
```

groupby('Date') regroupe toutes les ventes par jour et calcule la somme. Ensuite ax.plot() dessine une courbe. Ca montre comment les ventes evoluent dans le temps - on peut voir les pics et les creux.

plot_profit_evolution()

```
colors = ['#16A34A' if v > 0 else '#DC2626' for v in daily['Profit']]
```

Cette ligne cree une liste de couleurs : vert si le profit est positif, rouge si negatif. C'est ce qu'on appelle une list comprehension en Python - une facon courte d'ecrire une boucle.

plot_pub_vs_sales()

```
m, b = np.polyfit(data['Budget_Pub'], data['Prix_Final'], 1)
```

polyfit calcule la ligne de tendance (regression lineaire simple). m c'est la pente et b c'est l'ordonnee a l'origine. Ca montre si il y a une correlation entre la publicite et les ventes.

7. main.py - L'API FastAPI

Une API c'est un moyen pour d'autres applications de communiquer avec ton projet. Sans API, seul toi peux utiliser ton projet sur ton PC. Avec l'API, n'importe qui dans le monde peut l'utiliser via internet.

Comment ca marche une API REST ?

C'est comme commander dans un restaurant :

- Tu envoies une requete HTTP (tu commandes)
- L'API traite ta demande (le cuisinier prepare)
- Elle te renvoie une reponse en JSON (on t'apporte le plat)

C'est quoi JSON ?

JSON c'est un format de texte structure pour echanger des donnees. Exemple :

```
{ "ca_total": 5584334.0, "clients": 59, "top_categorie": "Robe/Jupe" }
```

C'est lisible par les humains et par les machines. Tous les sites web modernes utilisent JSON.

Les 4 endpoints de l'API

GET /summary	Retourne les statistiques globales : CA total, profit, top clients, top produits. Comme un tableau de bord.
POST /predict	Tu envoies un prix et une quantite, l'API te repond avec le CA predit par le modele ML.
GET /segments	Retourne la segmentation RFM : combien de VIP, Regulars, Occasionnels et leurs stats.
GET /model/info	Retourne les metriques du modele : R2, RMSE, et quelles features sont les plus importantes.

Comment tester l'API

Lance dans le terminal :

```
uvicorn main:app --reload
```

Puis ouvre <http://127.0.0.1:8000/docs> dans ton navigateur. Tu verras Swagger UI - une interface qui te permet de tester chaque endpoint en cliquant, sans ecrire de code.

Les schemas Pydantic

```
class PredictRequest(BaseModel):  
    prix_unitaire: float = Field(..., gt=0)  
    quantite: float = Field(default=1.0)
```

Pydantic verifie automatiquement que les donnees recues sont correctes. `gt=0` veut dire 'greater than 0' - si quelqu'un envoie un prix negatif, l'API refuse automatiquement avec un message d'erreur.

8. analysis.ipynb - Le Notebook Jupyter

Un notebook Jupyter c'est un document special qui melange du texte, du code Python, et des graphiques. C'est l'outil standard en Data Science pour presenter une analyse.

Pourquoi utiliser un notebook ?

- Tu peux executer le code cellule par cellule
- Les graphiques s'affichent directement dans le document
- Tu peux ecrire des explications entre le code
- C'est parfait pour montrer ton travail a quelqu'un

Les 8 sections du notebook

Section 1	Setup : importer toutes les librairies, charger les donnees, entrainer le modele. DOIT etre execute en premier.
Section 2	Business Summary : affiche les KPIs globaux du dataset reel.
Section 3	Revenue par categorie : deux graphiques cote a cote - nb transactions et CA par categorie.
Section 4	Evolution mensuelle : courbe du CA et du profit mois par mois de 2021 a 2022.
Section 5	Top 10 clients : graphique horizontal des meilleurs clients par CA.
Section 6	Segmentation RFM : barres et camembert des segments VIP/Regulier/Occasionnel.
Section 7	Distribution des prix : boxplot des prix par categorie de produit.
Section 8	Predictions : graphique montrant les predictions du modele selon le prix.

IMPORTANT : tu dois toujours executer les cellules dans l'ordre, de haut en bas. La cellule 1 doit tourner avant toutes les autres.

9. Les librairies Python - c'est quoi ?

Une librairie c'est un ensemble de fonctions deja ecrites par d'autres personnes que tu peux utiliser dans ton code. C'est comme des plugins.

pandas	La librairie pour manipuler des tableaux de donnees. Tu l'utilises avec pd. Elle permet de lire des CSV, filtrer des lignes, calculer des moyennes, etc. C'est la librairie la plus importante en Data Science.
numpy	Pour les calculs mathematiques. Tu l'utilises avec np. Elle permet de creer des matrices, calculer des moyennes, des deviations standard, etc. Tres rapide pour les calculs numeriques.
matplotlib	Pour creer des graphiques. Tu l'utilises avec plt. Elle permet de dessiner des courbes, des barres, des camemberts, des nuages de points, etc.
scikit-learn	La librairie standard pour le Machine Learning en Python. Elle contient Linear Regression, Random Forest, Gradient Boosting, et plein d'autres algorithmes. Tu l'utilises avec sklearn.
FastAPI	Pour creer des APIs web modernes en Python. Tres rapide et genere automatiquement une documentation interactive (Swagger UI).
pydantic	Pour valider les donnees. Verifie automatiquement que les donnees recues par l'API sont du bon type et dans les bonnes limites.
uvicorn	Le serveur web qui fait tourner l'API FastAPI. C'est lui qui ecoute les requetes HTTP et les passe a FastAPI.
jupyter	Pour ouvrir et editer les notebooks .ipynb. C'est l'environnement interactif ou tu executes le code cellule par cellule.

10. GitHub et Git - comment ca marche ?

Git c'est un systeme qui sauvegarde l'historique de ton code. GitHub c'est un site web quiheberge ton code en ligne.

Les commandes Git que tu as utilisees

git init	Initialise un nouveau depot Git dans ton dossier. A faire une seule fois au debut.
git add .	Selectionne tous les fichiers modifies pour les inclure dans le prochain commit. Le point signifie 'tout'.
git commit -m '...'	Sauvegarde un snapshot de ton code avec un message. C'est comme prendre une photo de ton projet a un instant T.
git push origin master:main --force	Envoie tes commits sur GitHub. --force force l'envoi meme si il y a des conflits.
git remote add origin ...	Connecte ton depot local au depot GitHub en ligne.

Pourquoi mettre son code sur GitHub ?

- Les recruteurs peuvent voir ton code directement
- Le README s'affiche automatiquement comme une page web
- C'est la reference mondiale pour partager du code
- Tu peux travailler depuis n'importe quel ordinateur

11. Le parcours complet des donnees

Voici comment les donnees voyagent dans ton projet de bout en bout :

Etape 1	dataset_real.csv contient 6978 transactions brutes. C'est le point de depart.
Etape 2	load_data() lit le CSV et cree un DataFrame pandas.
Etape 3	clean_data() enleve les lignes avec des valeurs manquantes ou dupliques.
Etape 4	create_time_features() extrait le mois et le jour depuis la date.
Etape 5	calculate_metrics() calcule le CA, le profit par unite.
Etape 6	prepare_ml_data() extrait les 4 features pour le modele ML.

Etape 7	SalesPredictor.train() entraine le modele sur 80% des donnees.
Etape 8	L'API FastAPI expose tout ca via 4 endpoints accessibles sur internet.
Etape 9	Le notebook visualise tout avec des graphiques interactifs.

12. Vocabulaire Data Science a connaitre

DataFrame	Un tableau de donnees en Python (lignes et colonnes). L'objet de base de pandas.
Feature	Une variable d'entree du modele ML. Dans notre cas : Prix_Unitaire, Quantite, Mois_Num, Jour_Semaine.
Target / y	Ce qu'on veut predire. Dans notre cas : le CA (Chiffre d'Affaires).
Train / Test split	Diviser les donnees en 80% pour apprendre et 20% pour tester le modele.
Overfitting	Quand le modele apprend trop bien les donnees d'entrainement mais se trompe sur les nouvelles. A eviter.
R2 Score	Mesure de precision entre 0 et 1. 1 = parfait, 0 = inutile.
RMSE	Erreur quadratique moyenne. L'erreur moyenne des predictions dans la meme unite que y.
RFM	Recency, Frequency, Monetary. Methode de segmentation clients basee sur 3 criteres.
API REST	Interface web qui permet d'echanger des donnees entre applications via HTTP.
JSON	Format texte pour echanger des donnees. Standard du web moderne.
Endpoint	Une URL specifique de l'API. Ex: /summary, /predict, /segments.
Feature Importance	Mesure de l'influence de chaque feature sur les predictions du modele.

Felicitations Khadija !

Tu as construit un projet Data Science complet avec de vraies donnees.

github.com/khadija-sk/e-commerce-sales-analysis